

## 第六章 条件期望与均方估值

陈斌

# Outline

- 1 条件期望
- 2 均方估值
- 3 线性均方最优估计
- 4 高斯马尔可夫过程

# 条件期望

$$\begin{aligned} E(X | Y = y) &= \int_{-\infty}^{+\infty} x dP(X \leq x | Y = y) \\ &= \int_{-\infty}^{+\infty} x dF(x | Y = y) = \int_{-\infty}^{+\infty} x dF(x | y) \end{aligned}$$

称为  $X$  关于  $\{Y = y\}$  的**条件数学期望**.

一般情况, 设  $X, Y$  的联合分布为  $F(x, y)$

$$dF(x|y) = \begin{cases} \text{离散} & \Pr(X = x|Y = y) \\ \text{连续} & f(x|y) = \frac{f(x,y)}{f_Y(y)} = \frac{f(x,y)}{\int_{\mathbb{R}} f(x,y)dx} \end{cases}$$

设  $X, Y$  为离散型随机变量, 分布为  $\Pr\{X = x_i, Y = y_j\}$ .

在  $Y = y_j$  条件下,  $X$  的均值为

$$E(X|Y = y_j) = \sum_i x_i \Pr\{X = x_i|Y = y_j\}.$$

当  $Y$  的取值变动时,  $EX|Y$  也相应变动,

**故  $EX|Y$  是  $Y$  的函数, 是一个随机变量。**

由全概率公式  $\Pr(X = x_i) = \sum_j \Pr(X = x_i|Y = y_j) \Pr(Y = y_j)$

$$\begin{aligned}
 \text{故 } EX &= \sum_i x_i \Pr(X = x_i) = \sum_i x_i \sum_j \Pr(X = x_i|Y = y_j) \Pr(Y = y_j) \\
 &= \sum_j \Pr(Y = y_j) \cdot \sum_i x_i \Pr(X = x_i|Y = y_j) \\
 &= \sum_j \Pr(Y = y_j) E(X|Y = y_j) = EE(X|Y) \quad \text{全期望公式}
 \end{aligned}$$

定义:

$EX|Y \triangleq \int_{\mathbb{R}} x dF(x|y)$  称为  $X$  关于  $Y$  的条件数学期望。

$EX|Y \triangleq g(Y)$  是  $Y$  的函数, 当  $Y = y$  时其值为  $E(X|Y = y)$ .

$$\begin{aligned}
 \text{注: } EE(X|Y) &= Eg(Y) = \int g(y) dF_Y(y) \\
 &= \int E(X|Y = y) dF_Y(y) = \int E(X|Y = y) f_Y(y) dy \\
 EE(X|Y) &= \sum_j E(X|Y = y_j) \Pr(Y = y_j)
 \end{aligned}$$

求条件期望的方法:  $EY | X = ?$ 

$$E(Y | X = x) \triangleq \int_{\mathbb{R}} y dF(y | x) = \int_{\mathbb{R}} y f_{Y|X}(y | x) dy$$

① 求  $f(x, y)$

② 求  $f_X(x) = \int_{\mathbb{R}} f(x, y) dy$

③ 用  $f_{Y|X}(y | x) = \frac{f(x, y)}{f_X(x)}$ , 求出条件密度

④  $E(Y | X = x) = \int_{\mathbb{R}} y f_{Y|X}(y | x) dy \Rightarrow E(Y | X)$

设  $(X_1, X_2) \sim N(\mu_1, \mu_2, r, \sigma_1^2, \sigma_2^2)$  二元联合高斯向量

条件概率密度:  $f(x_1|x_2) = \frac{f(x_1, x_2)}{f(x_2)}$

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-r^2}} \exp \left\{ -\frac{1}{2(1-r^2)} \left[ \left( \frac{x_1 - \mu_1}{\sigma_1} \right)^2 - 2r \left( \frac{x_1 - \mu_1}{\sigma_1} \right) \left( \frac{x_2 - \mu_2}{\sigma_2} \right) + \left( \frac{x_2 - \mu_2}{\sigma_2} \right)^2 \right] \right\}$$

$$f_2(x_2) = \int_{\mathbb{R}} f(x_1, x_2) dx_1 = \frac{1}{\sqrt{2\pi}\sigma_2} \exp \left\{ -\frac{(x_2 - \mu_2)^2}{2\sigma_2^2} \right\}$$

$$\begin{aligned} \text{故 } f(x_1|x_2) &= \frac{1}{\sqrt{2\pi}\sigma_1\sqrt{1-r^2}} \\ &\quad \cdot \exp \left\{ -\frac{1}{2(1-r^2)\sigma_1^2} \left[ x_1 - \mu_1 - \frac{\sigma_1}{\sigma_2} r(x_2 - \mu_2) \right]^2 \right\} \end{aligned}$$

当  $X_2 = x_2$  时,  $X_1$  服从  $N(\mu_1 + \frac{\sigma_1}{\sigma_2} r(x_2 - \mu_2), \sigma_1^2(1-r^2))$

故由条件期望定义,

$$EX_1|X_2 = \mu_1 + \frac{\sigma_1}{\sigma_2} r(X_2 - \mu_2) = \mu_1 + \frac{C(X_1, X_2)}{C(X_2, X_2)} (X_2 - \mu_2)$$

$$EX_1 = EX_1 = \mu_1$$

性质:

- ①  $EC|X = C$ ,  $C$ 为常数
- ②  $EX|X = X$ ;  $Eg(X)|X = g(X)$ ,  $g$ 为确定性函数
- ③ 线性  $E(C_1X_1 + C_2X_2)|Y = C_1EX_1|Y + C_2EX_2|Y$

性质:  $Eg(Y)X|Y = g(Y) \cdot EX|Y$

$$\begin{aligned} \text{证: } \forall y, E\{g(Y) \cdot X|Y = y\} &= \int_{\mathbb{R}} g(y) \cdot x dF(X|Y = y) \\ &= g(y) \int_{\mathbb{R}} x dF(X|Y = y) = g(y)E(X|Y = y) \end{aligned}$$

<sup>1</sup>一般  $E[q(X, Y) | Y = y] = \int q(x, y) dF(x | Y = y)$

性质:

- ①  $EC|X = C$ ,  $C$  为常数
- ②  $EX|X = X$ ;  $Eg(X)|X = g(X)$ ,  $g$  为确定性函数
- ③ 线性  $E(C_1X_1 + C_2X_2)|Y = C_1EX_1|Y + C_2EX_2|Y$

性质:  $Eg(Y)X|Y = g(Y) \cdot EX|Y$

$$\begin{aligned} \text{证: } \forall y, E\{g(Y) \cdot X|Y = y\} &= \int_{\mathbb{R}} g(y) \cdot x dF(X|Y = y) \\ &= g(y) \int_{\mathbb{R}} x dF(X|Y = y) = g(y)E(X|Y = y) \end{aligned}$$

性质:  $EEEX|Y = EX$ ,  $(EEEX|Y \triangleq \int_{\mathbb{R}} E(X|Y = y) dF_Y(y))$  全期望公式

证: 考虑连续情形, 离散情形已证。

$$\begin{aligned} E(X|Y = y) &= \int_{\mathbb{R}} x dF(X|Y = y) = \int_{\mathbb{R}} x f(x|y) dx \\ EEX|Y &= \int_{\mathbb{R}} \int_{\mathbb{R}} x f(x|y) dx dF_Y(y) = \int_{\mathbb{R}} \int_{\mathbb{R}} x f(x|y) f_Y(y) dx dy \\ &= \int_{\mathbb{R}} \int_{\mathbb{R}} x f(x, y) dx dy = \int_{\mathbb{R}} x f_X(x) dx = EX \end{aligned}$$

<sup>1</sup>一般  $E[q(X, Y) | Y = y] = \int q(x, y) dF(x | Y = y)$



多元随机变量(向量)的条件期望:

$E(X|Y_1, \dots, Y_n)$  是随机向量  $Y$  的函数,

当  $Y = y$  时, 取值  $E(X|Y = y) \triangleq E(X|Y_1 = y_1, \dots, Y_n = y_n)$

类似地有: 随机向量  $Y = (Y_1, \dots, Y_n)^T$

- ① 线性  $EC_1X_1 + C_2X_2|Y = C_1EX_1|Y + C_2EX_2|Y$
- ②  $E[g(Y_1, \dots, Y_n)X|Y] = g(Y_1, \dots, Y_n)EX|Y$
- ③ 若  $X$  与  $Y_1, \dots, Y_n$  独立, 则  $EX|Y = EX$
- ④  $EE(X|Y_1, \dots, Y_n) = EX$  作业

# 均方估值

已知随机变量  $X$  可观测,  $X$  与未知随机变量  $Y$  相关

若  $X, Y$  的二阶矩存在, 如何使用  $X$  去估计  $Y$  ?

*i.e.*, 寻找  $X$  的某个函数  $g(X)$ , *s.t.*  $g(X)$  与  $Y$  之间的误差最小

均方准则:  $\min_g E|Y - g(X)|^2$ , *i.e.*  $\min_g \|Y - g(X)\|$

设  $g^*$  满足  $\min E|Y - g(X)|^2 = E|Y - g^*(X)|^2$ , 如何求  $g^*$ ?

**定理:**  $E|Y - g(X)|^2 \geq E|Y - E(Y|X)|^2$  *i.e.*  $g^*(X) = EY|X$

证: 由于  $EY|X$  是  $X$  的函数, 故可令  $E(Y|X) \triangleq \hat{g}(x)$

$$\begin{aligned} E|Y - g(X)|^2 &= E|Y - \hat{g}(X) + \hat{g}(X) - g(X)|^2 \\ &= E|Y - \hat{g}(X)|^2 + E(Y - \hat{g}(X))(\hat{g}(X) - g(X)) \\ &\quad + E(\overline{Y - \hat{g}(X)})(\hat{g}(X) - g(X)) + E|\hat{g}(X) - g(X)|^2 \\ &\geq E|Y - \hat{g}(X)|^2 \end{aligned}$$

等号在  $E|\hat{g}(X) - g(X)|^2 = 0$  时成立  $\Leftrightarrow g(X) = EY|X$ , *a.e.*

(接上一页证明：)

使用全期望公式<sup>2</sup>

$$\begin{aligned}
 & E(Y - \hat{g}(X)) \cdot (\overline{\hat{g}(X) - g(X)}) \\
 = & {}^3 E\{E[Y - \hat{g}(X)] [\overline{\hat{g}(X) - g(X)}] | X\} \\
 = & E\{[\overline{\hat{g}(X) - g(X)}] E[Y - \hat{g}(X)] | X\} \\
 = & E\{[\overline{\hat{g}(X) - g(X)}] [EY | X - E\hat{g}(X) | X]\} \\
 = & 0 \quad \text{其中 } EY | X = \hat{g}(X) \text{ 且 } E\hat{g}(X) | X = \hat{g}(X)
 \end{aligned}$$

结论： $EY | X$  是  $Y$  的最佳均方估计，称为  $Y$  关于  $X$  的回归。

用  $EY | X$  预测  $Y$  可使均方误差最小！

<sup>2</sup>  $EE(X | Y) = EX, E(g(X) | X) = g(X)$

<sup>3</sup>  $Eg(Y)h(X, Y) | Y = g(Y) \cdot Eh(X, Y) | Y$

例:  $X = (X_1, X_2)$   $n$ 元高斯  $N(\mu, \mathbf{B})$ ,  $X_1, X_2$  为子 (行) 向量  
 $\mu_{X_1} = \mu_1, \mu_{X_2} = \mu_2, \mathbf{B} = \begin{pmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{pmatrix}$ , 求  $EX_2|X_1$ ?<sup>4</sup>

解: 在二元情形, 求出  $f(y|x)$ , 然后对  $y$  配方, 得到均值。  
 但在  $n$  元情形, 这种方法十分繁琐, 很难得到结果。

解决方案: 化  $\mathbf{B}$  为对角(分块)矩阵, 简化处理。

$$\text{令 } (Y_1, Y_2)^T = ((X_1, X_2) \begin{pmatrix} \mathbf{I} & -\mathbf{B}_{11}^{-1}\mathbf{B}_{12} \\ \mathbf{0} & \mathbf{I} \end{pmatrix})^T,$$

$$\text{显然 } Y_1 = X_1, Y_2 = X_2 - X_1\mathbf{B}_{11}^{-1}\mathbf{B}_{12}.$$

$$\mu_Y = (\mu_1, \mu_2 - \mu_1\mathbf{B}_{11}^{-1}\mathbf{B}_{12})^T = (\mu_{y_1}, \mu_{y_2})^T{}^5$$

$$\mathbf{B}_Y = \begin{pmatrix} \mathbf{I} & \mathbf{0} \\ -\mathbf{B}_{21} & \mathbf{B}_{11}^{-1}\mathbf{I} \end{pmatrix} \begin{pmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{pmatrix} \begin{pmatrix} \mathbf{I} & \mathbf{0} \\ -\mathbf{B}_{21} & \mathbf{B}_{11}^{-1}\mathbf{I} \end{pmatrix}^T = \begin{pmatrix} \mathbf{B}_{11} & \mathbf{0} \\ \mathbf{0} & \mathbf{B}_{22} - \mathbf{B}_{21}\mathbf{B}_{11}^{-1}\mathbf{B}_{12} \end{pmatrix}$$

$$Y_1 \text{ 与 } Y_2 \text{ 独立, } Jacobi = \left| \begin{pmatrix} \mathbf{I} & \mathbf{0} \\ -\mathbf{B}_{21} & \mathbf{B}_{11}^{-1}\mathbf{I} \end{pmatrix}^{-1} \right| = 1,$$

<sup>4</sup> 用  $X_1$  去估计  $X_2$

<sup>5</sup>  $\eta = \mathbf{C}\xi, E\eta = \mathbf{C}E\xi, \mathbf{B}_\eta = \mathbf{C}\mathbf{B}_\xi\mathbf{C}^T$

故  $f_Y(y_1, y_2) = f_Y(y_1)f_Y(y_2) = f_X(x_1, x_2)$ .

$$Y_1 = X_1 \Rightarrow f_Y(y_1) = f_X(x_1).$$

故  $f_X(x_2|x_1) = \frac{f_X(x_1, x_2)}{f_X(x_1)} = \frac{f_Y(y_1, y_2)}{f_Y(y_1)} = f_Y(y_2)$ ,

即当  $x_1$  给定时, 其概率密度可以表示如下:

$$f_{X_2}(x_2|x_1) = f_Y(y_2) = \frac{1}{(2\pi)^{\frac{n_2}{2}} |\mathbf{B}_{y_2}|^{\frac{1}{2}}} \exp\left\{-\frac{1}{2}(y_2 - \mu_{y_2})\mathbf{B}_{y_2}^{-1}(y_2 - \mu_{y_2})\right\}^6.$$

由  $Y_2 = X_2 - \mathbf{B}_{21} \mathbf{B}_{11}^{-1} X_1$ , 可知

$$\begin{aligned} y_2 - \mu_{y_2} &= x_2 - x_1 \mathbf{B}_{11}^{-1} \mathbf{B}_{12} - (\mu_2 - \mu_1 \mathbf{B}_{11}^{-1} \mathbf{B}_{12}) \\ &= x_2 - [\mu_2 + (x_1 - \mu_1) \mathbf{B}_{11}^{-1} \mathbf{B}_{12}] \\ &= x_2 - E(X_2|X_1 = x_1), \end{aligned}$$

故  $E(X_2|X_1) = \mu_2 + (X_1 - \mu_1) \mathbf{B}_{11}^{-1} \mathbf{B}_{12}$ .

<sup>6</sup>为高斯分布的概率密度, 即  $f_{X_2}(x_2|x_1)$  服从高斯分布!

$E(X_2 | X_1)$  的另外一种表示:

$$\begin{cases} X_1 = Y_1 \\ X_2 = B_{21}B_{11}^{-1}Y_1 + Y_2 \end{cases}, \quad Y_1, Y_2 \text{ 相互独立}$$

$$\begin{aligned} E(X_2 | X_1) &= E((\mathbf{B}_{21}\mathbf{B}_{11}^{-1}Y_1 + Y_2) | Y_1) \\ &= E(\mathbf{B}_{21}\mathbf{B}_{11}^{-1}Y_1 | Y_1) + E(Y_2 | Y_1) \\ &= \mathbf{B}_{21}\mathbf{B}_{11}^{-1}Y_1 + E(Y_2) \\ &= \mathbf{B}_{21}\mathbf{B}_{11}^{-1}X_1 + E(X_2 - \mathbf{B}_{21}\mathbf{B}_{11}^{-1}X_1) \\ &= E(X_2) + \mathbf{B}_{21}\mathbf{B}_{11}^{-1}(X_1 - E(X_1)) \\ &= \mu_2 + \mathbf{B}_{21}\mathbf{B}_{11}^{-1}(X_1 - \mu_1) \end{aligned}$$

$Y$  随机变量,  $X_n, X_{n-1}, \dots$  为可观测的随机序列

(有限或无限均可, 为方便假设有限)

若用  $X_n, \dots, X_1$  的某个函数作为  $Y$  的估计  $Y^*$ ,

使得误差在均方意义下最小, *i.e.*

$$E|Y - g^*(X_n, \dots, X_1)|^2 = \min_g E|Y - g(X_n, \dots, X_1)|^2$$

$$Y^* \triangleq g^*(X_n, \dots, X_1)$$

**定理 (推广)**:  $Y^* = g^*(X_n, \dots, X_1) = EY|X_n, \dots, X_1$

证明方法与一维情况类似, 留为作业(与Markov链一齐交)

# 线性均方最佳预测

$E Y|X$  作为最优估计理论上很完美，但实际应用中很难求得！  
 在求解全局最优困难时，人们常常退一步求解“局部/条件最优”  
 在所有函数中求最佳估计  $\rightarrow$  在线性函数中求最佳估计

$H$ ：所有二阶矩变量组成的线性空间， $Y \in H$ ，实二阶矩

$H_n$ ：包含  $X_n, X_{n-1}, \dots$  的线性子空间， $H_n \subset H$

$H$  为 Hilbert 空间，可定义内积和距离，范数。

求： $\hat{Y}^* \in H_n$  使得误差  $Y - \hat{Y}^*$  最小， i.e.

$$E|Y - \hat{Y}^*|^2 = \min_{\hat{Y} \in H_n} E|Y - \hat{Y}|^2$$


**记号（定义）：**

$$\|Y - \hat{Y}\| \triangleq \sqrt{E|Y - \hat{Y}|^2}, \quad d(Y, \hat{Y}) \triangleq \|Y - \hat{Y}\| \quad \text{距离}$$

$$(Y, \hat{Y}) \triangleq EY\hat{Y} \quad \text{内积, 垂直} \Leftrightarrow \text{正交} \Leftrightarrow \text{内积为0}$$



# 正交性原理



$H_n$  为  $H$  中的一个 (超) 平面

目标: 求  $\hat{Y}^*$  使得  $\|Y - \hat{Y}^*\|^2$  最小

显然当  $Y - \hat{Y}^* \perp H_n$  时,  $\|Y - \hat{Y}^*\|$  最小



$$\forall u \in H_n, \quad E(Y - \hat{Y}^*)u = 0$$

**定理:**  $\hat{Y}^*$  是  $Y$  对  $X_n, X_{n-1}, \dots$  的线性均方最佳估计, *iff*

$$\forall u \in H_n, \text{ 满足 } E(Y - \hat{Y}^*)u = 0$$

(类比初中数学中的证明线面垂直)

# 非退化随机变量：二维情形

**例：** 设有随机变量 $\xi, \eta$ , 已知 $E\eta^n = m_n, n \geq 2, E\eta = 0, \xi = \eta^2$ 。若以 $\eta$ 的观察值对 $\xi$ 作线性估计, 求其最佳估计。

**解：** 根据题意 $\mu_\xi = E\xi = E\eta^2 = m_2 \neq 0$ ,

于是最佳线性估计 $\hat{\xi}$ 应具有如下形式

$$\hat{\xi} = a\eta + b, \quad 1, \eta \text{ 张成的线性子空间}$$

所谓最佳是指 $E[\xi - \hat{\xi}]^2 = E[\xi - (a\eta + b)]^2$ 取极小值, 就是选择 $a, b$ 值以使 $E[\xi - \hat{\xi}]^2$ 最小。

现利用正交性原理求解;

$$E\{\xi - a\eta - b\} = 0 \Rightarrow b = E\xi = m_2$$

$$E\{[\xi - (a\eta + b)]\eta\} = 0 \Rightarrow E\xi\eta = aE\eta^2$$

$$\text{即 } a = \frac{E\xi\eta}{E\eta^2} = \frac{E\eta^3}{E\eta^2} = \frac{m_3}{m_2}$$

$$\text{故 } \hat{\xi} = \frac{m_3}{m_2}\eta + m_2$$

**定理：** $\hat{Y}^*$  是  $Y$  对  $X_n, X_{n-1}, \dots$  的线性均方最佳估计, *iff*  
 $\forall u \in H_n$ , 满足  $E(Y - \hat{Y}^*)u = 0$

**讨论一：**若  $X_n = C$  常数

$$\text{令 } \hat{Y}^* = \sum a_k X_k,$$

$$\text{则 } E(Y - \hat{Y}^*)C = 0 \Rightarrow EY = E\hat{Y}^* = \sum a_k EX_k \quad \text{无偏估计}$$

$$\Rightarrow Y - \sum a_k X_k = Y - EY - (\hat{Y}^* - E\hat{Y}^*)$$

$$= (Y - EY) - \sum a_k (X_k - EX_k)$$

即  $\{X_k\}$  对  $Y$  的最佳估计  $\Leftrightarrow (Y - EY)$  对  $\{X_k - EX_k\}$  的最佳估计

故为讨论方便, 不妨设  $Y, X_n, X_{n-1}, \dots, 0$  均值

**定理：** $\hat{Y}^*$  是  $Y$  对  $X_n, X_{n-1}, \dots$  的线性均方最佳估计, *iff*  
 $\forall u \in H_n$ , 满足  $E(Y - \hat{Y}^*)u = 0$

**讨论一：**若  $X_n = C$  常数

$$\text{令 } \hat{Y}^* = \sum a_k X_k,$$

$$\text{则 } E(Y - \hat{Y}^*)C = 0 \Rightarrow EY = E\hat{Y}^* = \sum a_k EX_k \quad \text{无偏估计}$$

$$\Rightarrow Y - \sum a_k X_k = Y - EY - (\hat{Y}^* - E\hat{Y}^*)$$

$$= (Y - EY) - \sum a_k (X_k - EX_k)$$

即  $\{X_k\}$  对  $Y$  的最佳估计  $\Leftrightarrow (Y - EY)$  对  $\{X_k - EX_k\}$  的最佳估计

故为讨论方便, 不妨设  $Y, X_n, X_{n-1}, \dots, 0$  均值

**讨论二：**不妨设  $Y, X_n, X_{n-1}, \dots, 0$  均值

若  $Y$  与  $X_n, X_{n-1}, \dots$  不相关, 则无法用  $X_n, \dots$  估计  $Y$

$$EYX_i = EYE X_i = 0 \Leftrightarrow Y \perp X_i \Leftrightarrow Y \perp H_n \Leftrightarrow \hat{Y}^* = 0$$

**定理:**  $\hat{Y}^*$  是  $Y$  对  $X_n, X_{n-1}, \dots$  的线性均方最佳估计, *iff*  
 $\forall u \in H_n$ , 满足  $E(Y - \hat{Y}^*)u = 0$

**定理：** $\hat{Y}^*$  是  $Y$  对  $X_n, X_{n-1}, \dots$  的线性均方最佳估计, *iff*  
 $\forall u \in H_n$ , 满足  $E(Y - \hat{Y}^*)u = 0$

**讨论三：**

设  $Y - \hat{Y}^* = e$ ,  $\hat{Y}^* = \sum_{k=0}^{\infty} \alpha_k X_{n-k}$

由于  $X_i \in H_n$ , 故  $EeX_i = 0$ ,  $i = n, n-1, \dots$

*i.e.*  $E(Y - \sum_{k=0}^{\infty} \alpha_k X_{n-k})X_i = 0$

$\Leftrightarrow EYX_i = \sum_k \alpha_k EX_{n-k}X_i$

$\Leftrightarrow R(Y, X_i) = \sum_k \alpha_k R(X_{n-k}, X_i) \quad i = n, n-1, \dots$  线性方程组

**定理：** $\hat{Y}^*$  是  $Y$  对  $X_n, X_{n-1}, \dots$  的线性均方最佳估计, *iff*  
 $\forall u \in H_n$ , 满足  $E(Y - \hat{Y}^*)u = 0$

**讨论三：**

设  $Y - \hat{Y}^* = e$ ,  $\hat{Y}^* = \sum_{k=0}^{\infty} \alpha_k X_{n-k}$

由于  $X_i \in H_n$ , 故  $EeX_i = 0$ ,  $i = n, n-1, \dots$

*i.e.*  $E(Y - \sum_{k=0}^{\infty} \alpha_k X_{n-k})X_i = 0$

$\Leftrightarrow EYX_i = \sum_k \alpha_k EX_{n-k}X_i$

$\Leftrightarrow R(Y, X_i) = \sum_k \alpha_k R(X_{n-k}, X_i) \quad i = n, n-1, \dots$  线性方程组

若  $EY = E\hat{Y}^* = \sum \alpha_k EX_{n-k}$

$\Rightarrow EYX_i - EYE X_i = \sum \alpha_k (EX_{n-k}X_i - EX_{n-k}EX_i)$

$\Leftrightarrow C(Y, X_i) = \sum \alpha_k C(X_{n-k}, X_i) \quad i = n, n-1, \dots$  线性方程组

若已知相关矩阵(或协方差矩阵), 可解出  $\alpha_k$

从而求出  $\hat{Y}^*$ , 即最佳均方线性估计





若  $X_n, X_{n-1}, \dots$  两两正交,  $R(X_j, X_i) = 0, j \neq i$ ,

$$\text{则 } \alpha_{n-i} = \frac{R(Y, X_i)}{R(X_i, X_i)} \quad 7$$

**若  $\{X_n\}$  是二阶矩过程,  $R(\tau)$  是相关函数**

已知  $X_n, X_{n-1}, \dots, X_{n-p}$ , 求  $X_{n+1}$  的估计  $\hat{X}_{n+1}^*$

$$\text{令 } \hat{X}_{n+1}^* = \sum_{k=0}^p \alpha_k X_{n-k}$$

$$R(X_{n+1}, X_i) = \sum \alpha_k R(X_{n-k}, X_i) \quad i = n, n-1, \dots, n-p$$

$$\begin{cases} \alpha_0 R(n, n) + \alpha_1 R(n-1, n) + \dots + \alpha_p R(n-p, n) = R(n+1, n) \\ \alpha_0 R(n, n-1) + \alpha_1 R(n-1, n-1) + \dots + \alpha_p R(n-p, n-1) = R(n+1, n-1) \\ \vdots \\ \alpha_0 R(n, n-p) + \alpha_1 R(n-1, n-p) + \dots + \alpha_p R(n-p, n-p) = R(n+1, n-p) \end{cases}$$

解出  $\alpha_0, \dots, \alpha_p$ , 即得  $\hat{X}_{n+1}^*$

结论: 可见, 线性最优均方估计有系统的方法可以解出

---


$$^7 R(Y, X_i) = \sum \alpha_k R(X_{n-k}, X_i), i = n, n-1, \dots$$

若  $\{X_n\}$  是实宽平稳过程,  $R(\tau)$  是相关函数;

已知  $X_n, X_{n-1}, \dots, X_{n-p}$ , 求  $X_{n+1}$  的估计  $\hat{X}_{n+1}^*$

$$\text{令 } \hat{X}_{n+1}^* = \sum_{k=0}^p \alpha_k X_{n-k}$$

$$R(X_{n+1}, X_i) = \sum_k \alpha_k R(X_{n-k}, X_i) \quad i = n, n-1, \dots, n-p$$

$$\begin{aligned} R(n+1-i) &= \sum_{k=0}^p \alpha_k R(n-k-i) \\ &= \sum_{k=0}^{n-i} \alpha_k R(n-k-i) + \sum_{k=n-i+1}^p \alpha_k R(k+i-n) \end{aligned}$$

上述方程可写为:

$$\begin{cases} \alpha_0 R(0) + \alpha_1 R(1) + \cdots + \alpha_p R(p) = R(1) \\ \alpha_0 R(1) + \alpha_1 R(0) + \alpha_2 R(1) + \cdots + \alpha_p R(p-1) = R(2) \\ \vdots \\ \alpha_0 R(p) + \alpha_1 R(p-1) + \alpha_2 R(p-2) + \cdots + \alpha_p R(0) = R(p+1) \end{cases}$$

i.e. 约尔-沃克方程

$$\begin{pmatrix} R(0) & R(1) & \cdots & R(p) \\ R(1) & R(0) & \cdots & R(p-1) \\ \vdots & & \ddots & \vdots \\ R(p) & R(p-1) & \cdots & R(0) \end{pmatrix} \begin{pmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{pmatrix} = \begin{pmatrix} R(1) \\ R(2) \\ \vdots \\ R(p+1) \end{pmatrix}$$

上式左边矩阵对称，称为托普利兹矩阵

解方程组求得  $\alpha = (\alpha_0, \alpha_1, \cdots, \alpha_p)$ ,  $\hat{X}_{n+1}^* = \sum_{k=0}^p \alpha_k X_{n-k}$

## 高斯马尔可夫过程

定义:  $\{\xi(t), t \in T\}$ ,  $t_1 < t_2 < \cdots < t_m < t_{m+1} \in T$

$f(x_{m+1}|x_1, x_2, \cdots x_m) = f(x_{m+1}|x_m)$ , 称Markov过程

定理: 设  $\{\xi(t)\}$  为实 0 均值高斯Markov过程

则  $R(t_1, t_3) = \frac{R(t_1, t_2)R(t_2, t_3)}{R(t_2, t_2)} \quad t_1 < t_2 < t_3$

证:  $R(t_1, t_3) = E\xi(t_1)\xi(t_3)$

$$= \int_{\mathbb{R}} \int_{\mathbb{R}} \int_{\mathbb{R}} x_1 x_3 f(x_1, x_2, x_3) dx_1 dx_2 dx_3$$

其中  $f(x_1, x_2, x_3) = f(x_1) \cdot f(x_2|x_1) \cdot f(x_3|x_2)$  (Markov)

$$= \int_{\mathbb{R}} \int_{\mathbb{R}} x_1 f(x_1) f(x_2|x_1) \cdot \left[ \int_{\mathbb{R}} x_3 f(x_3|x_2) dx_3 \right] dx_2 dx_1$$

其中  $\int_{\mathbb{R}} x_3 f(x_3|x_2) dx_3 = E[\xi(t_3)|\xi(t_2) = x_2]$

